

Projeto Susana (SUS-DF) - Visão Arquitetural

Visão Geral

O Projeto Susana é uma assistente virtual administrativa construída para a Secretaria de Saúde do Distrito Federal (SES-DF). O objetivo primário é fornecer informações sobre os serviços do SUS (horários, marcações, documentação para a Farmácia de Alto Custo, locais de vacinação) sem infringir normativas médicas.

Soberania de Dados e Privacidade (LGPD)

Para garantir controle total sobre os dados sensíveis e compliance absoluto com a LGPD, a arquitetura foi desenhada de forma 100% "on-premise". Nenhuma API externa (como OpenAI ou Google Gemini) é utilizada. Tudo roda nos servidores locais da Secretaria.

Arquitetura de Inteligência Artificial

- Modelo Base (LLM): Llama 3.1 8B, executado localmente através da engine Ollama, oferecendo alto desempenho na geração de texto em português brasileiro.
- Retrieval-Augmented Generation (RAG): O sistema consulta um banco vetorial local (ChromaDB) indexado através do modelo de embedding "all-MiniLM-L6-v2" via sentence-transformers, garantindo que as respostas sejam exclusivamente fundamentadas em documentos oficiais raspados do portal saude.df.gov.br.

Segurança Clínica (ML Guardrails)

A assistente é rigorosamente proibida de fazer triagem médica ou sugerir medicamentos. Para isso, foi desenvolvido um classificador híbrido:

- Um modelo Machine Learning (Logistic Regression + TF-IDF, em scikit-learn) intercepta intenções clínicas com probabilidade > 65%.
- Sistema Fallback de Regex "Fail-Closed" garante bloqueio se o modelo falhar.

Práticas de Engenharia MLOps

Os modelos e experimentos são rastreados através do ecossistema MLflow, com datasets controlados no DVC. A arquitetura de software Backend adota o padrão Hexagonal (Ports & Adapters) desenvolvido no FastAPI.